Importando as bibliotecas

```
from matplotlib import pyplot
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
import seaborn as sns
import tensorflow as tf
import random
import keras
import collections
from keras.datasets import mnist
from keras.utils import np utils
from keras.models import Sequential
from keras.layers.core import Dense
from keras.layers.core import Activation
from keras.layers.core import Dropout
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.metrics import categorical_crossentropy
from sklearn.metrics import confusion matrix
 /wsr/local/lib/python3.6/dist-packages/statsmodels/tools/_testing.py:19: FutureWarnir
       import pandas.util.testing as tm
     Using TensorFlow backend.
Carregando os dados MNIST para variáveis
(X_train, y_train), (X_test, y_test) = mnist.load_data()
```

```
(X_train, y_train), (X_test, y_test) = mnist.load_data()

#Verificando quantidade para treino e teste
print('Imagens de treino:', X_train.shape[0])
print('Imagens de teste:', X_test.shape[0])

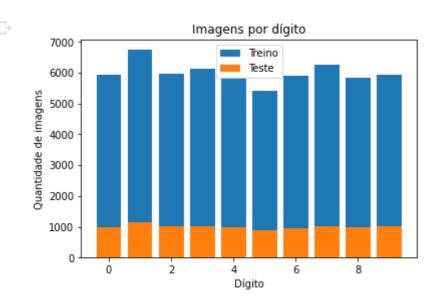
Imagens de treino: 60000
Imagens de teste: 10000
```

Mostrando quantidade de dados para treino e teste por dígito

```
counterTrain=collections.Counter(y_train)
counterTest=collections.Counter(y_test)

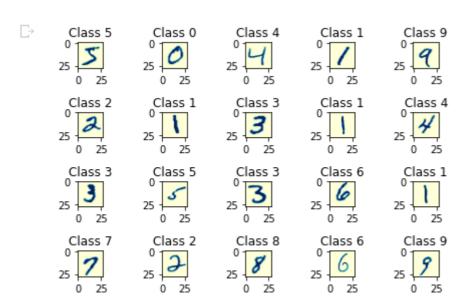
fig, ax = pyplot.subplots()
rects1 = ax.bar(counterTrain.keys(), counterTrain.values(), label='Treino')
rects3 = ax.bar(counterTest.keys(), counterTest.values(), label='Teste')
```

```
ax.set_title('Imagens por dígito')
ax.set_ylabel('Quantidade de imagens')
ax.set_xlabel('Dígito')
ax.legend()
pyplot.show()
```



Plotando os primeiros exemplos para verificar os dados

```
for i in range(20):
    plt.subplot(4,5,i+1)
    plt.imshow(X_train[i], cmap='YlGnBu')
    plt.title("Class {}".format(y_train[i]))
plt.tight_layout()
```



Alterando de matriz para vetor (estrutura dos digitos) para padrão do KERAS

```
#Alterando de matriz 28x28 para vetor 1x784
X_train = X_train.reshape(60000, 784)
X_test = X_test.reshape(10000, 784)
```

```
#Alterando valores dos pixels para float (garantindo precisão em operações de divisão por
X train = X train.astype('float32')
X_test = X_test.astype('float32')
#Normalizando os valores dos pixels (valores entre 0 e 1)
X_train /= 255
X_test /= 255
Converte as classes dos vetores em binário
nClasses = 10
Y_train = np_utils.to_categorical(y_train, nClasses)
Y_test = np_utils.to_categorical(y_test, nClasses)
Criando o modelo
#Iniciando o modelo
model = Sequential()
#Criando a primeira camada com 512 neurônios
model.add(Dense(512, input shape=(784,)))
#Utilizando a função de ativação ReLu
model.add(Activation('relu'))
#Dropout de 20% dos neuronios
model.add(Dropout(0.2))
#Criando a segunda camada, com as mesmas características que a primeira
model.add(Dense(512))
model.add(Activation('relu'))
model.add(Dropout(0.2))
#Criando a camada de saída, com 10 (um para cada dígito) neurônios e a função SoftMax para
model.add(Dense(10))
model.add(Activation('softmax'))
#Mostra o modelo criado
model.summary()
```

Model: "sequential 1"

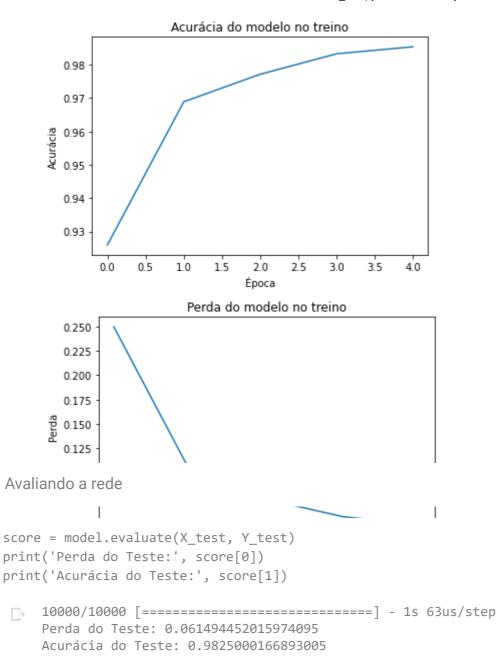
Layer (type)	Output Shape	Param #
=======================================		:=========
dense_1 (Dense)	(None, 512)	401920
activation_1 (Activation)	(None, 512)	0
dropout_1 (Dropout)	(None, 512)	0

Criando um otimizador para rede

Treinando o modelo

Plotando o histórico de treino (Acurácia e Perda)

```
#Histórico de acurácia
pyplot.plot(historico.history['accuracy'])
pyplot.title('Acurácia do modelo no treino')
pyplot.ylabel('Acurácia')
pyplot.xlabel('Época')
pyplot.show()
#Histórico de perda
pyplot.plot(historico.history['loss'])
pyplot.title('Perda do modelo no treino')
pyplot.ylabel('Perda')
pyplot.xlabel('Época')
pyplot.show()
```

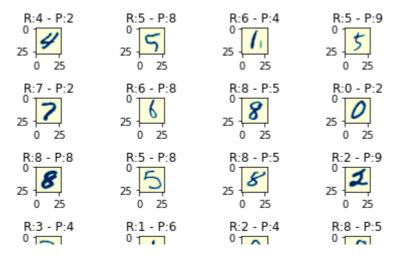


Gerando as previsões

```
previsoes = model.predict classes(X test)
```

Verificando as previsões

```
plt.figure()
for i in range(16):
    plt.subplot(4,4,i+1)
    num = random.randint(0, len(X_test))
    plt.imshow(X_test[num].reshape(28,28), cmap='YlGnBu')
    plt.title("R:{} - P:{}".format(previsoes[num], y_train[num]))
plt.tight_layout()
```

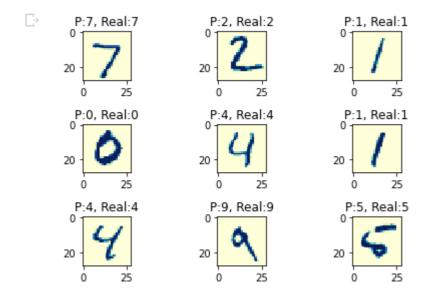


Verificando apenas previsões corretas

```
#Comparando as previsões com os dados de teste e guardando os indíces corretos
idxCorreto = np.nonzero(previsoes == y_test)[0]
```

```
plt.figure()
for i, correto in enumerate(idxCorreto[:9]):
    plt.subplot(3,3,i+1)
    plt.imshow(X_test[correto].reshape(28,28), cmap='YlGnBu', interpolation='none')
    plt.title("P:{}, Real:{}".format(previsoes[correto], y_test[correto]))

plt.tight_layout()
```

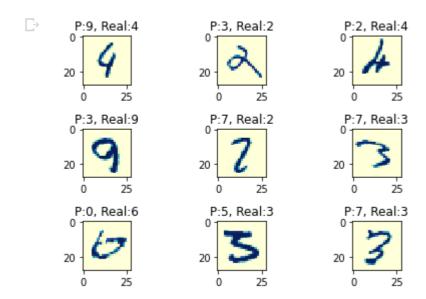


Verificando apenas previsões incorretas

```
#Comparando as previsões com os dados de teste e guardando os indíces incorretos
idxIncorreto = np.nonzero(previsoes != y_test)[0]

plt.figure()
for i, incorreto in enumerate(idxIncorreto[:9]):
    plt.subplot(3,3,i+1)
    plt.imshow(X_test[incorreto].reshape(28,28), cmap='YlGnBu', interpolation='none')
    plt.title("P:{}, Real:{}".format(previsoes[incorreto], y_test[incorreto]))
```

plt.tight_layout()



Matriz de confusão para verificar os erros

```
confusao = confusion_matrix(y_test, previsoes)
plt.figure(figsize=(15, 7))
sns.heatmap(confusao, annot=True,vmin=0, vmax=1000, cmap="YlGnBu", center = 0)
plt.show()
```

